

Định hướng policy đi bộ cho robot hình người Unitree G1 bằng Adversarial Imitation Learning trên mjlalab

Báo cáo kỹ thuật – Sprint 1

Trần Phú Nghĩa

28/09/2026

Tóm tắt nội dung

Báo cáo nghiên cứu việc thay thế các reward term quy định đáng đi của policy đi bộ cho robot hình người Unitree G1 trong mjlalab bằng một reward học từ dữ liệu mẫu theo hướng adversarial inverse reinforcement learning. Một discriminator được huấn luyện để phân biệt transition của expert với transition của policy; đầu ra của nó được dùng làm style reward, kết hợp với task reward bám vận tốc. Với reward kết hợp có tỉ trọng style lớn, replay buffer cho discriminator, discriminator có điều kiện theo lệnh và reference state initialization (RSI), policy đạt tracking error 0,20 m/s (expert 0,16 m/s), độ cao nhấc chân 5,7 cm (expert 7,5 cm) và 92% tổng reward viết tay của expert sau 2000 iteration, trong khi chưa từng được huấn luyện với các reward term này. Thí nghiệm ablation cho thấy RSI là thành phần quyết định.

1 Bài toán

Điều khiển đi bộ được mô hình hóa là một MDP $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma)$. Tại mỗi bước t ($\Delta t = 0,02$ s), policy $\pi_\theta(a_t | o_t)$ nhận quan sát o_t (vận tốc thân, hướng trọng lực, góc và vận tốc 29 khớp, hành động trước và lệnh vận tốc $c = (v_x^*, v_y^*, \omega_z^*)$) và xuất hành động $a_t \in \mathbb{R}^{29}$ là độ lệch góc khớp so với tư thế mặc định. Policy được tối ưu bằng PPO [5] để cực đại hóa $J(\theta) = \mathbb{E}_{\pi_\theta} [\sum_t \gamma^t r_t]$ với $\gamma = 0,99$.

Cấu hình gốc của mjlalab dùng reward gồm 14 term viết tay: hai term bám vận tốc

$$r_t^G = \Delta t \left(2 e^{-\|c_{xy} - v_{xy}\|^2 / 0,25} + 2 e^{-(c_\omega - \omega_z)^2 / 0,5} \right), \quad (1)$$

với v_{xy}, ω_z là vận tốc dài và vận tốc xoay thực của thân, cùng 12 term quy định đáng đi (thân thẳng, tư thế khớp, độ giật hành động, độ cao nhấc chân, trượt chân, tự va chạm, ...). Ta gọi r^G là *task reward*.

Mục tiêu. Chỉ giữ r^G ; thay 12 term đáng đi bằng *style reward* r^S học từ dữ liệu của một expert, sao cho policy đi theo lệnh với đáng đi giống expert và hội tụ trong ≤ 2000 iteration.

2 Phương pháp

2.1 Adversarial imitation learning (GAIL)

Gọi ρ_π là phân phối transition mà policy π sinh ra. Imitation learning tìm π sao cho ρ_π gần với phân phối của expert ρ_E . GAIL [1] đặt bài toán thành một trò chơi min-max giữa policy và một discriminator $D_\psi : \mathcal{S} \times \mathcal{S} \rightarrow \mathbb{R}$ (đầu ra là logit d):

$$\min_{\pi} \max_{\psi} \mathbb{E}_{(s,s') \sim \mathcal{D}_E} [\log \sigma(d)] + \mathbb{E}_{(s,s') \sim \pi} [\log(1 - \sigma(d))], \quad d = D_\psi(s, s'), \quad (2)$$

với σ là hàm sigmoid và $\mathcal{D}_E$ là tập transition của expert. Ở điểm tối ưu của discriminator, giá trị hàm mục tiêu tương đương divergence Jensen-Shannon giữa ρ_π và ρ_E (sai khác một hằng số), nên cực tiểu theo π tương ứng với kéo hai phân phối lại gần nhau.

Discriminator được huấn luyện như một bộ phân loại nhị phân:

$$\mathcal{L}_D(\psi) = -\mathbb{E}_{\mathcal{D}_E} [\log \sigma(d)] - \mathbb{E}_{\mathcal{B}_\pi} [\log(1 - \sigma(d))] + \frac{w_{gp}}{2} \mathbb{E}_{\mathcal{D}_E} [\|\nabla_{(s,s')} d\|^2], \quad (3)$$

trong đó $\mathcal{B}_\pi$ là tập transition của policy và số hạng cuối là gradient penalty [4] ($w_{gp} = 10$), giữ D tròn quanh dữ liệu expert.

Style reward là reward mà policy nhận được từ discriminator:

$$r^S(s, s') = -\log(1 - \sigma(d)) = \log(1 + e^d). \quad (4)$$

r^S tăng đơn điệu theo xác suất $\sigma(d)$ mà discriminator gán cho việc transition thuộc expert; cực đại hóa r^S tương ứng với cực tiểu (2) theo π . Policy và discriminator được cập nhật xen kẽ. Trong báo cáo này chỉ phần reward của GAIL được dùng; policy được tối ưu bằng PPO thay cho TRPO của bài gốc.

Discriminator trên transition. GAIL gốc dùng cặp (trạng thái, hành động). Ở đây discriminator nhận cặp trạng thái liên tiếp (s_t, s_{t+1}) (imitation from observation), để không phụ thuộc vào không gian hành động của expert.

Bão hòa. Nếu discriminator phân biệt quá dễ ($d \ll 0$ trên dữ liệu policy) thì $r^S \approx 0$ và gradient của nó theo trạng thái gần bằng 0: policy mất tín hiệu style. Đây là chế độ thất bại chính của các cấu hình trước.

2.2 Adversarial Motion Priors (AMP)

AMP [2] là một biến thể của GAIL cho điều khiển chuyển động. Khác biệt chính nằm ở hàm mục tiêu của discriminator: thay entropy chéo bằng hồi quy bình phương tối thiểu (least-squares GAN) về nhãn +1 cho expert và -1 cho policy,

$$\mathcal{L}_D^{\text{AMP}} = \mathbb{E}_{\mathcal{D}_E} [(d-1)^2] + \mathbb{E}_{\mathcal{B}_\pi} [(d+1)^2] + \frac{w_{gp}}{2} \mathbb{E}_{\mathcal{D}_E} [\|\nabla d\|^2], \quad r_{\text{AMP}}^S = \max(0, 1 - \frac{1}{4}(d-1)^2). \quad (5)$$

Style reward của AMP bị chặn trong $[0, 1]$ và đạt cực đại khi $d = 1$ (giá trị gán cho expert); reward của GAIL (4) không bị chặn trên. AMP cũng đề xuất replay buffer, RSI và đặc trưng vị trí bàn chân, bàn tay cho discriminator. Báo cáo so sánh hai hàm mục tiêu này (Mục 3).

2.3 Kết hợp reward

Reward đưa cho PPO là tổ hợp lồi của task reward và style reward:

$$r_t = \lambda r_t^G + (1 - \lambda) w_S \Delta t r^S(s_t, s_{t+1}), \quad \lambda = 0.3, w_S = 4, \quad (6)$$

theo Escontrela et al. [3]. Hệ số $w_S \Delta t$ đưa r^S về cùng thang đo với r^G (đã nhân Δt), để style chiếm khoảng 70% tổng reward. Cặp (s_t, s_{t+1}) nằm ở hai phía của một lần reset không phải là transition thật và bị loại.

2.4 Đặc trưng của discriminator

Trạng thái đưa vào discriminator là $s = \Phi(\cdot) \in \mathbb{R}^{83}$, tính bằng cùng một hàm cho expert và policy: vận tốc dài và vận tốc góc của thân trong hệ tọa độ thân (6), hướng trọng lực trong hệ thân (3), độ cao thân (1), góc và vận tốc 29 khớp (58), vị trí hai bàn chân và hai bàn tay so với thân trong hệ thân (12), và lệnh vận tốc c (3). Việc đưa c vào làm discriminator *có điều kiện theo lệnh*: nó so sánh chuyển động của policy với chuyển động của expert dưới cùng một lệnh, thay vì với phân phối chuyển động gộp của mọi lệnh. Đầu vào được chuẩn hóa bằng trung bình và độ lệch chuẩn của dữ liệu expert.

2.5 Ổn định huấn luyện

- **Replay buffer.** $\mathcal{B}_\pi$ trong (3) được lấy mẫu từ một bộ đệm FIFO chứa 10^6 transition gần nhất của policy, thay vì chỉ rollout của iteration hiện tại. Discriminator do đó không khớp quá mức với policy hiện tại, giảm bão hòa [2].
- **Không dùng entropy bonus.** Khi không còn term phạt độ gập, entropy bonus làm độ lệch chuẩn của hành động tăng liên tục; transition nhiều dễ bị phân biệt và discriminator bão hòa. Độ lệch chuẩn ban đầu $\sigma_0 = 1$ được giữ để đủ khám phá.


2.6 Reference State Initialization (RSI)

Mỗi episode bắt đầu từ một trạng thái lấy từ phân phối ban đầu ρ_0 (ở đây: tư thế đứng mặc định với nhiều nhỏ). RSI [2] thay ρ_0 bằng hỗn hợp với phân phối trạng thái của dữ liệu mẫu:

$$s_0 \sim (1 - p) \rho_0 + p \rho_E, \quad p = 0,85. \quad (7)$$

Khi thu dữ liệu expert, ngoài đặc trưng Φ ta lưu trạng thái mô phỏng đầy đủ (độ cao, hướng, vận tốc dài và góc của thân, góc và vận tốc khớp); khi một episode reset, với xác suất p robot được đặt vào một trạng thái như vậy. Policy do đó được huấn luyện ngay từ đầu trên các pha của chu kỳ bước chân của expert, thay vì phải tự khám phá chúng từ tư thế đứng — điều khó xảy ra khi style reward đã thưởng cho việc đứng với tư thế giống expert.

2.7 Tóm tắt thuật toán



Hình 1: Luồng dữ liệu. Bước 1 thực hiện một lần; bước 2–6 lặp lại mỗi iteration.

- Dữ liệu mẫu.** Chạy expert tắt định trên 512 môi trường trong 10 s với lệnh ngẫu nhiên; lưu $|\mathcal{D}_E| = 256\,000$ cặp (s, s') và các trạng thái mô phỏng cho RSI. Expert là một policy PPO huấn luyện với đủ 14 reward term (3000 iteration).
- Rollout.** 4096 môi trường $\times$ 24 bước; episode reset theo (7); ghi (s_t, s_{t+1}) và r_t^G .
- Style reward.** Tính r^S theo (4) (hoặc (5)).
- Kết hợp** theo (6).
- Cập nhật policy** bằng PPO (GAE $\lambda = 0,95$, clip 0,2, 5 epoch $\times$ 4 mini-batch, learning rate 10^{-3} thích nghi theo KL).
- Cập nhật discriminator.** Thêm transition của rollout vào $\mathcal{B}_\pi$; thực hiện 5 bước Adam (learning rate 10^{-4} , batch 4096) trên (3) với mẫu từ $\mathcal{D}_E$ và $\mathcal{B}_\pi$.

Policy và critic là MLP 512–256–128 (ELU); discriminator là MLP 1024–512 (ReLU).

3 Thí nghiệm

Ablation. Bốn cấu hình được huấn luyện song song trên một GPU, mỗi cấu hình thêm một thành phần; các thiết lập còn lại giống hệt nhau (cùng expert, PPO, 4096 môi trường, 2000 iteration, seed 42).

	Kết hợp (6) + replay buffer	Discriminator có điều kiện	RSI	Hàm mục tiêu D
v7a	✓			GAIL
v7b	✓	✓		GAIL
v7c	✓	✓	✓	GAIL
v7d	✓	✓	✓	AMP

Mốc so sánh: expert và GAIL v4b — cấu hình tốt nhất trước đó (reward cộng $r^G + 2\Delta t r^S$, không replay buffer, không RSI, 1500 iteration, học từ một expert cũ).


Giao thức đánh giá. Mọi policy được đánh giá trong cùng một lần chạy: 512 môi trường $\times$ 1000 bước (20 s), seed 123, lệnh ngẫu nhiên theo phân phối huấn luyện, không đẩy robot, policy tắt định. Các chỉ số:

- *Speed ratio* $v/v^* = \sum_t v_{xy} c_{xy} / \sum_t \|c_{xy}\|^2$ (1: đúng lệnh; 0: đứng yên) và *tracking error* $e = \|c_{xy} - v_{xy}\|$ (m/s).
- *Dáng bước* (khi $\|c_{xy}\| > 0,2$ m/s): số lần chạm đất mỗi giây của mỗi bàn chân, và độ cao cực đại của bàn chân trong một bước.
- *True reward* $\bar{R}$: tổng 14 reward term viết tay trên giây — hàm reward mà các policy học (trừ expert) chưa từng được tối ưu.


4 Kết quả

Bảng 1: Kết quả đánh giá tại iteration 2000.

	$v/v^* \uparrow$	e (m/s) $\downarrow$	Chạm đất/s	Nhấc chân (cm)	$\bar{R} \uparrow$	$\bar{R} / \text{expert}$
Expert	0,84	0,16	2,0	7,5	5,03	100%
GAIL v4b	0,81	0,18	6,6	1,4	3,18	63%
v7a	0,20	0,54	3,8	1,0	3,68	73%
v7b	0,32	0,47	4,4	1,2	3,77	75%
v7c	0,80	0,20	2,5	5,7	4,63	92%
v7d	0,17	0,57	2,8	3,1	3,63	72%



Hình 2: Lệnh tiến 0,5 m/s, khung hình tại $t = 1, \dots, 5$ s.



Hình 3: Diễn biến huấn luyện (làm mượt EMA). (a) Reward bám vận tốc dài trung bình mỗi episode. (b) Style reward trung bình. (c) Hiệu $\bar{d}_E - \bar{d}_\pi$ giữa logit trung bình của discriminator trên dữ liệu expert và trên dữ liệu policy.

Cấu hình đầy đủ (v7c). Policy đi theo lệnh gần mức expert ($v/v^* = 0,80$ so với 0,84; $e = 0,20$ so với 0,16 m/s) và đạt 92% true reward của expert. So với GAIL v4b, hiện tượng lê chân được khắc phục: số lần chạm đất giảm từ 6,6 xuống 2,5 lần/giây (expert 2,0) và độ cao nhấc chân tăng từ 1,4 lên 5,7 cm (expert 7,5). True reward tại iteration 500 / 1000 / 1500 / 2000 lần lượt là 89% / 91% / 92% / 92% của expert: phần lớn quá trình hội tụ diễn ra trong 500–1000 iteration đầu.

Hội tụ của trò chơi đối kháng. Với v7c, hiệu $\bar{d}_E - \bar{d}_\pi$ giảm dần về gần 0 (Hình 3c), tức discriminator ngày càng khó phân biệt transition của policy với của expert, trong khi style reward giữ ở mức cao nhất trong các cấu hình (Hình 3b). Không cấu hình nào bị bão hòa.

Ablation.

- *RSI là thành phần quyết định.* Không có RSI (v7a, v7b), policy gần như đứng yên ($v/v^* \leq 0,32$). Khi style reward chiếm phần lớn (6), đứng với tư thế giống expert đã cho reward cao, và policy xuất phát từ tư thế đứng không khám phá được chu kỳ bước chân. RSI đưa policy vào các trạng thái của chu kỳ này ngay từ đầu.
- *Discriminator có điều kiện cải thiện nhẹ* (v7b so với v7a).
- *Hàm mục tiêu GAIL tốt hơn AMP* trên bài toán này (v7c so với v7d); nhất quán với các cấu hình trước.

Khoảng cách còn lại so với expert: độ cao nhấc chân (5,7 so với 7,5 cm), tần số bước (2,5 so với 2,0 lần/giây) và tốc độ (95% của expert).

5 Kết luận

Một style reward học bằng adversarial imitation learning thay thế được 12 reward term đáng đi viết tay cho bài toán bám vận tốc của G1: policy đạt 92% true reward của expert mà không được tối ưu trực tiếp trên nó, với dáng bước gần expert, trong 2000 iteration. Ba điều kiện cần là (i) style reward chiếm tỉ trọng lớn trong reward kết hợp, (ii) discriminator được giữ khỏi bão hòa (replay buffer, không entropy bonus, gradient penalty), và (iii) reference state initialization để policy tiếp cận chu kỳ bước chân của expert.

Tài liệu

- [1] J. Ho, S. Ermon. Generative adversarial imitation learning. *NeurIPS*, 2016.
- [2] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, A. Kanazawa. AMP: Adversarial motion priors for stylized physics-based character control. *ACM TOG (SIGGRAPH)*, 2021.

- [3] A. Escontrela, X. B. Peng, W. Yu, T. Zhang, A. Iscen, K. Goldberg, P. Abbeel. Adversarial motion priors make good substitutes for complex reward functions. *IROS*, 2022.
- [4] L. Mescheder, A. Geiger, S. Nowozin. Which training methods for GANs do actually converge? *ICML*, 2018.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov. Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.