

Định hướng policy đi bộ cho robot hình người Unitree G1 bằng Adversarial Imitation Learning trên mjlalab

Báo cáo kỹ thuật – Sprint 1

Trần Phú Nghĩa

28/09/2026

Tóm tắt nội dung

Báo cáo nghiên cứu việc thay thế các reward term quy định đáng đi của policy đi bộ cho robot hình người Unitree G1 trong mjlalab bằng một reward học từ dữ liệu mẫu theo hướng adversarial inverse reinforcement learning. Một discriminator được huấn luyện để phân biệt transition của expert với transition của policy; đầu ra của nó được dùng làm style reward, kết hợp với task reward bám vận tốc. Với reward kết hợp có tỉ trọng style lớn, replay buffer cho discriminator, discriminator có điều kiện theo lệnh và reference state initialization (RSI), policy đạt tracking error 0,20 m/s (expert 0,16 m/s), độ cao nhấc chân 5,7 cm (expert 7,5 cm) và 92% tổng reward viết tay của expert sau 2000 iteration, trong khi chưa từng được huấn luyện với các reward term này. Thí nghiệm ablation cho thấy RSI là thành phần quyết định.

1 Bài toán

Điều khiển đi bộ được mô hình hóa là một MDP $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma)$. Tại mỗi bước t ($\Delta t = 0,02$ s), policy $\pi_\theta(a_t | o_t)$ nhận quan sát o_t (vận tốc thân, hướng trọng lực, góc và vận tốc 29 khớp, hành động trước và lệnh vận tốc $c = (v_x^*, v_y^*, \omega_z^*)$) và xuất hành động $a_t \in \mathbb{R}^{29}$ là độ lệch góc khớp so với tư thế mặc định. Policy được tối ưu bằng PPO [5] để cực đại hóa $J(\theta) = \mathbb{E}_{\pi_\theta} [\sum_t \gamma^t r_t]$ với $\gamma = 0,99$.

Cấu hình gốc của mjlalab dùng reward gồm 14 term viết tay: hai term bám vận tốc (*task reward* r^G , (1)) và 12 term quy định đáng đi (thân thẳng, tư thế khớp, độ giật hành động, độ cao nhấc chân, trượt chân, tự va chạm, ...).

Mục tiêu. Chỉ giữ r^G ; thay 12 term đáng đi bằng *style reward* r^S học từ dữ liệu của một expert, sao cho policy đi theo lệnh với đáng đi giống expert và hội tụ trong ≤ 2000 iteration.


2 Phương pháp

2.1 Tổng quan

Thuật toán huấn luyện đồng thời hai mạng neural (Bảng 1). Reward của policy lấy một phần từ discriminator: transition được discriminator đánh giá càng giống của expert thì policy nhận reward càng lớn. Discriminator được tối ưu để tách transition của expert khỏi transition của policy, còn policy được tối ưu để xóa sự khác biệt đó; khi discriminator không còn phân biệt được, phân phối chuyển động của policy trùng với của expert.

Bảng 1: Hai mạng được huấn luyện.

Mạng	Đầu vào	Đầu ra	Mục tiêu tối ưu
Policy π_θ (kèm critic V_ϕ)	quan sát o_t (99 chiều)	hành động $a_t \in \mathbb{R}^{29}$ (góc đặt cho 29 khớp)	cực đại tổng reward có chiết khấu
Discriminator D_ψ	cặp (s_t, s_{t+1}) , 2×83 chiều	logit $d \in \mathbb{R}$	phân loại transition: expert (1) hay policy (0)



Hình 1: Luồng dữ liệu. Dữ liệu expert được thu một lần; các bước A–D (Mục 2.3) lặp lại mỗi iteration.

2.2 Chuẩn bị dữ liệu

Expert là một policy PPO đã huấn luyện với đủ 14 reward term (3000 iteration). Chạy expert tắt định 10 s trên 512 môi trường với lệnh ngẫu nhiên, ta thu hai tập dữ liệu:

Tập transition $\mathcal{D}_E$ gồm 256 000 cặp (s_t, s_{t+1}) . Mỗi $s = \Phi(\cdot) \in \mathbb{R}^{83}$ là vector mô tả chuyển động, tính bằng cùng một hàm cho expert và policy:

Thành phần	Số chiều
Vận tốc dài và vận tốc góc của thân (hệ tọa độ thân)	3 + 3
Hướng trọng lực trong hệ thân (độ nghiêng của thân)	3
Độ cao thân	1
Góc và vận tốc 29 khớp	29 + 29
Vị trí 2 bàn chân và 2 bàn tay so với thân (hệ thân)	12
Lệnh vận tốc c	3

Discriminator nhận *cặp* trạng thái liên tiếp vì một trạng thái đơn lẻ chỉ mô tả tư thế, còn cặp liên tiếp mô tả chuyển động. Việc đưa lệnh c vào s làm discriminator *có điều kiện theo lệnh*: chuyển động của policy được so với chuyển động của expert dưới cùng một lệnh, thay vì với phân phối gộp của mọi lệnh. Đầu vào được chuẩn hóa bằng trung bình và độ lệch chuẩn của $\mathcal{D}_E$.

Tập trạng thái cho RSI gồm 46 080 trạng thái mô phỏng đầy đủ của expert (độ cao, hướng, vận tốc dài và góc của thân, góc và vận tốc từng khớp), lấy mỗi 5 bước sau giây đầu tiên, tức khi expert đang đi và trải đều các pha của chu kỳ bước chân.

2.3 Một iteration

Mỗi iteration gồm bốn bước A–D; huấn luyện chạy 2000 iteration.

A. Rollout. 4096 môi trường chạy song song 24 bước ($\approx 98\,000$ bước). Tại mỗi bước, trên mỗi môi trường:

1. Policy lấy mẫu hành động $a_t \sim \mathcal{N}(\mu_\theta(o_t), \sigma^2 I)$. Độ lệch chuẩn σ là tham số học được, khởi tạo $\sigma_0 = 1$; không có entropy bonus nên σ giảm dần trong quá trình huấn luyện.
2. Mô phỏng tiến 20 ms; ghi cặp (s_t, s_{t+1}) .
3. *Task reward* đo mức bám lệnh (v : vận tốc thực, c : lệnh):

$$r_t^G = \Delta t \left(2e^{-\|c_{xy} - v_{xy}\|^2 / 0.25} + 2e^{-(c_\omega - \omega_z)^2 / 0.5} \right) \in [0; 0.08]. \quad (1)$$

4. *Style reward* từ discriminator: $d = D_\psi(s_t, s_{t+1})$ và

$$r_t^S = -\log(1 - \sigma(d)) = \log(1 + e^d), \quad (2)$$

tăng đơn điệu theo xác suất $\sigma(d)$ mà discriminator gán cho việc transition thuộc expert.

5. *Reward kết hợp* đưa cho PPO, theo [3]:

$$r_t = \lambda r_t^G + (1 - \lambda) w_S \Delta t r_t^S, \quad \lambda = 0,3, \quad w_S = 4. \quad (3)$$

Hệ số $w_S \Delta t$ đưa r^S về cùng thang đo với r^G ; trong huấn luyện, thành phần style chiếm khoảng 60–70% tổng reward.

6. Khi episode kết thúc (ngã hoặc hết 20 s), môi trường được reset. Với xác suất $p = 0,85$ robot được đặt vào một trạng thái lấy ngẫu nhiên từ tập trạng thái của expert (*reference state initialization*, RSI [2]); ngược lại bắt đầu từ tư thế đứng mặc định:

$$s_0 \sim (1 - p) \rho_0 + p \rho_E. \quad (4)$$

Cặp (s_t, s_{t+1}) nằm hai phía của lần reset không phải transition thật: nó bị loại khỏi dữ liệu của discriminator và nhận $r^S = 0$.

B. Cập nhật policy (PPO). Critic V_ϕ ước lượng tổng reward tương lai có chiết khấu ($\gamma = 0,99$); advantage $\hat{A}_t$ được tính bằng GAE ($\lambda_{\text{GAE}} = 0,95$) và cho biết hành động a_t tốt hơn hay kém hơn mức kỳ vọng. PPO tăng xác suất các hành động có $\hat{A}_t > 0$, giảm các hành động có $\hat{A}_t < 0$, với tỉ số xác suất giữa policy mới và cũ bị cắt trong $[0,8; 1,2]$ để mỗi lần cập nhật chỉ thay đổi policy một lượng nhỏ (5 epoch $\times$ 4 mini-batch, learning rate 10^{-3} thích nghi theo KL).

C. Replay buffer. Các cặp (s, s') hợp lệ của rollout được thêm vào bộ đệm FIFO $\mathcal{B}_\pi$ dung lượng 10^6 (tương đương khoảng 10 iteration gần nhất).

D. Cập nhật discriminator. Thực hiện 5 bước Adam (learning rate 10^{-4}), mỗi bước dùng 4096 cặp từ $\mathcal{D}_E$ (nhãn 1) và 4096 cặp từ $\mathcal{B}_\pi$ (nhãn 0):

$$\mathcal{L}_D(\psi) = \underbrace{-\mathbb{E}_{\mathcal{D}_E} [\log \sigma(d)] - \mathbb{E}_{\mathcal{B}_\pi} [\log(1 - \sigma(d))]}_{\text{phân loại nhị phân}} + \underbrace{\frac{w_{\text{gp}}}{2} \mathbb{E}_{\mathcal{D}_E} [\|\nabla_{(s,s')} d\|^2]}_{\text{gradient penalty, } w_{\text{gp}}=10}. \quad (5)$$

Hai số hạng đầu đẩy d lên với mẫu expert và xuống với mẫu policy. Gradient penalty [4] giới hạn độ dốc của d quanh dữ liệu expert, nhờ đó r^S biến thiên trơn và cung cấp hướng cải thiện rõ ràng cho policy.

2.4 Cơ sở lý thuyết

GAIL. Bước B và D cùng giải bài toán min–max [1]

$$\min_{\pi} \max_{\psi} \mathbb{E}_{\mathcal{D}_E} [\log \sigma(d)] + \mathbb{E}_{\pi} [\log(1 - \sigma(d))]. \quad (6)$$

Với discriminator tối ưu, giá trị này tương đương divergence Jensen–Shannon giữa phân phối transition của policy và của expert (sai khác một hằng số); cực tiểu theo π — thực hiện bằng cách cực đại hóa r^S ở (2) — kéo hai phân phối lại gần nhau. Báo cáo chỉ dùng phần reward của GAIL; policy được tối ưu bằng PPO thay cho TRPO của bài gốc, và discriminator nhận (s, s') thay cho (trạng thái, hành động).

AMP. Adversarial Motion Priors [2] là biến thể của GAIL cho điều khiển chuyển động, thay (5) bằng hồi quy bình phương tối thiểu về nhãn ± 1 và dùng style reward bị chặn trong $[0, 1]$:

$$\mathcal{L}_D^{\text{AMP}} = \mathbb{E}_{\mathcal{D}_E} [(d-1)^2] + \mathbb{E}_{\mathcal{B}_\pi} [(d+1)^2] + \frac{w_{\text{gp}}}{2} \mathbb{E}_{\mathcal{D}_E} [\|\nabla d\|^2], \quad r_{\text{AMP}}^S = \max(0, 1 - \frac{1}{4}(d-1)^2). \quad (7)$$

Replay buffer, RSI và đặc trưng vị trí bàn chân, bàn tay cũng được đề xuất trong AMP.

Bão hòa. Nếu discriminator phân biệt quá dễ ($d \ll 0$ trên dữ liệu policy) thì $r^S \approx 0$ và gradient của nó theo trạng thái gần bằng 0: policy mất tín hiệu style. Đây là chế độ thất bại chính của các cấu hình trước.

2.5 Vai trò của từng thành phần

Bảng 2: Hệ quả khi thiếu từng thành phần, quan sát được ở các cấu hình trước.

Thành phần	Khi thiếu	Quan sát
Kết hợp (3), style $\approx 70\%$	Style chỉ $\approx 10\%$ tổng reward; policy chủ yếu tối ưu r^G và chọn đáng đi dễ nhất để đạt vận tốc (bước ngắn, lê chân)	GAIL v4b: 6,6 lần chạm đất/s, nhắc chân 1,4 cm
Replay buffer	Discriminator khớp quá mức với policy hiện tại và bão hòa	v5: $\bar{d}_\pi \approx -9$, $r^S \approx 0,01$
Không entropy bonus	Độ lệch chuẩn hành động tăng tới 3,5–5; transition nhiều dễ bị phân biệt	v1
Discriminator có điều kiện	So với phân phối chuyển động gộp của mọi lệnh	v7b nhỉnh hơn v7a
RSI	Với style $\approx 70\%$, đứng yên với tư thế giống expert đã cho reward cao; policy xuất phát từ tư thế đứng không khám phá được chu kỳ bước chân	v7a, v7b: $v/v^* \leq 0,32$

Kết hợp (3) và RSI phải đi cùng nhau: tăng tỉ trọng style mà không có RSI dẫn tới policy đứng yên; với RSI, policy được huấn luyện ngay từ đầu trong các pha của chu kỳ bước chân và chỉ cần duy trì chúng, còn style reward kéo đáng đi về phía expert.

2.6 Giải mã

```

Thu một lần: chạy expert -> D_E (256k cap (s,s'), 83 chiều) + tập trạng thái RSI
Lap 2000 iteration:
  A. 4096 môi trường x 24 bước; tại mỗi bước:
      a ~ N(mu(o), sigma^2) # policy
      s' = mô phỏng(a)
      rG = reward bám vận tốc # (1)
      rS = log(1 + exp(D(s, s'))) # (2)
      r = 0.3*rG + 0.7*(4*0.02*rS) # (3)
      nếu reset: 85% đặt robot vào trạng thái expert (RSI); bỏ cap (s,s')
  B. PPO cập nhật policy và critic với reward r
  C. thêm ~98k cap (s,s') vào replay buffer (1 triệu cap mỗi ngày)
  D. 5 lần: 4096 cap expert (nhận 1) + 4096 cap từ buffer (nhận 0)
      -> bước Adam trên loss phân loại + gradient penalty # (5)

```

Policy và critic là MLP 512–256–128 (ELU); discriminator là MLP 1024–512 (ReLU).

3 Thí nghiệm

Ablation. Bốn cấu hình được huấn luyện song song trên một GPU, mỗi cấu hình thêm một thành phần; các thiết lập còn lại giống hệt nhau (cùng expert, PPO, 4096 môi trường, 2000 iteration, seed 42).

	Kết hợp (3) + replay buffer	Discriminator có điều kiện	RSI	Hàm mục tiêu D
v7a	✓			GAIL
v7b	✓	✓		GAIL
v7c	✓	✓	✓	GAIL
v7d	✓	✓	✓	AMP

Mốc so sánh: expert và GAIL v4b — cấu hình tốt nhất trước đó (reward cộng $r^G + 2\Delta t r^S$, không replay buffer, không RSI, 1500 iteration, học từ một expert cũ).


Giao thức đánh giá. Mọi policy được đánh giá trong cùng một lần chạy: 512 môi trường $\times$ 1000 bước (20 s), seed 123, lệnh ngẫu nhiên theo phân phối huấn luyện, không đẩy robot, policy tắt định. Các chỉ số:

- *Speed ratio* $v/v^* = \sum_t v_{xy} c_{xy} / \sum_t \|c_{xy}\|^2$ (1: đúng lệnh; 0: đứng yên) và *tracking error* $e = \overline{\|c_{xy} - v_{xy}\|}$ (m/s).
- *Dáng bước* (khi $\|c_{xy}\| > 0,2$ m/s): số lần chạm đất mỗi giây của mỗi bàn chân, và độ cao cực đại của bàn chân trong một bước.
- *True reward* $\bar{R}$: tổng 14 reward term viết tay trên giấy — hàm reward mà các policy học (trừ expert) chưa từng được tối ưu.


4 Kết quả

Bảng 3: Kết quả đánh giá tại iteration 2000.

	$v/v^* \uparrow$	e (m/s) $\downarrow$	Chạm đất/s	Nhấc chân (cm)	$\bar{R} \uparrow$	$\bar{R} / \text{expert}$
Expert	0,84	0,16	2,0	7,5	5,03	100%
GAIL v4b	0,81	0,18	6,6	1,4	3,18	63%
v7a	0,20	0,54	3,8	1,0	3,68	73%
v7b	0,32	0,47	4,4	1,2	3,77	75%
v7c	0,80	0,20	2,5	5,7	4,63	92%
v7d	0,17	0,57	2,8	3,1	3,63	72%



Hình 2: Lệnh tiến 0,5 m/s, khung hình tại $t = 1, \dots, 5$ s.



Hình 3: Diễn biến huấn luyện (làm mượt EMA). (a) Reward bám vận tốc dài trung bình mỗi episode. (b) Style reward trung bình. (c) Hiệu $\bar{d}_E - \bar{d}_\pi$ giữa logit trung bình của discriminator trên dữ liệu expert và trên dữ liệu policy.

Cấu hình đầy đủ (v7c). Policy đi theo lệnh gần mức expert ($v/v^* = 0,80$ so với 0,84; $e = 0,20$ so với 0,16 m/s) và đạt 92% true reward của expert. So với GAIL v4b, hiện tượng lê chân được khắc phục: số lần chạm đất giảm từ 6,6 xuống 2,5 lần/giây (expert 2,0) và độ cao nhấc chân tăng từ 1,4 lên 5,7 cm (expert 7,5). True reward tại iteration 500 / 1000 / 1500 / 2000 lần lượt là 89% / 91% / 92% / 92% của expert: phần lớn quá trình hội tụ diễn ra trong 500–1000 iteration đầu.

Hội tụ của trò chơi đối kháng. Với v7c, hiệu $\bar{d}_E - \bar{d}_\pi$ giảm dần về gần 0 (Hình 3c), tức discriminator ngày càng khó phân biệt transition của policy với của expert, trong khi style reward giữ ở mức cao nhất trong các cấu hình (Hình 3b). Không cấu hình nào bị bão hòa.

Ablation.

- *RSI là thành phần quyết định.* Không có RSI (v7a, v7b), policy gần như đứng yên ($v/v^* \leq 0,32$). Khi style reward chiếm phần lớn (3), đứng với tư thế giống expert đã cho reward cao, và policy xuất phát từ tư thế đứng không khám phá được chu kỳ bước chân. RSI đưa policy vào các trạng thái của chu kỳ này ngay từ đầu.
- *Discriminator có điều kiện cải thiện nhẹ* (v7b so với v7a).
- *Hàm mục tiêu GAIL tốt hơn AMP* trên bài toán này (v7c so với v7d); nhất quán với các cấu hình trước.

Khoảng cách còn lại so với expert: độ cao nhấc chân (5,7 so với 7,5 cm), tần số bước (2,5 so với 2,0 lần/giây) và tốc độ (95% của expert).

5 Kết luận

Một style reward học bằng adversarial imitation learning thay thế được 12 reward term đáng đi viết tay cho bài toán bám vận tốc của G1: policy đạt 92% true reward của expert mà không được tối ưu trực tiếp trên nó, với dáng bước gần expert, trong 2000 iteration. Ba điều kiện cần là (i) style reward chiếm tỉ trọng lớn trong reward kết hợp, (ii) discriminator được giữ khỏi bão hòa (replay buffer, không entropy bonus, gradient penalty), và (iii) reference state initialization để policy tiếp cận chu kỳ bước chân của expert.

Tài liệu

- [1] J. Ho, S. Ermon. Generative adversarial imitation learning. *NeurIPS*, 2016.
- [2] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, A. Kanazawa. AMP: Adversarial motion priors for stylized physics-based character control. *ACM TOG (SIGGRAPH)*, 2021.

- [3] A. Escontrela, X. B. Peng, W. Yu, T. Zhang, A. Iscen, K. Goldberg, P. Abbeel. Adversarial motion priors make good substitutes for complex reward functions. *IROS*, 2022.
- [4] L. Mescheder, A. Geiger, S. Nowozin. Which training methods for GANs do actually converge? *ICML*, 2018.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov. Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.